

系统设计

Distributed System Design

(九章网站下载最新课件)

课程版本 v6.0 本节主讲人：老顽童

版权声明：九章课程不允许录像，否则将追究法律责任，赔偿损失



扫描二维码关注微信/微博
获取最新面试题及权威解答

微信: [ninechapter](#)

微博: <http://www.weibo.com/ninechapter>

知乎: <http://zhuanlan.zhihu.com/jiuzhang>

官网: <http://www.jiuzhang.com>

什么是分布式系统？

一言以概之：用多台机器去解决一台机器上不能够解决的问题。

比如：存储不够？QPS太大？



- Distributed File System (Google File System)
 - 怎么有效存储数据?
 - No SQL 底层需要一个文件系统
- Bigtable = No-SQL Database
 - 怎么连接底层存储和上层数据
- Map Reduce
 - 怎么快速处理数据?

Design Distributed File System

了解分布式文件系统后可以做什么？

1. Google, Microsoft面试可能会考到.
2. 学习经典系统, 对其他系统设计也有帮助.
比如如何处理failure 和 recovery.

Distributed File System	Company	开源
GFS	Google	No
HDFS	Yahoo(Altaba)Open Source of GFS	Yes

Distributed File System

Hadoop Distributed File System
VS
Google File System(GFS)

1. 按照4S分析
 - **S**cenario 场景分析
 - **S**ervice 服务
 - **S**torage 存储
2. 理清楚work solution
3. Scale 升级优化

Scenario 场景分析

需要设计哪些功能

- 需求1
 - 用户写入一个文件, 用户读取一个文件.
 - 总存储量有多大?
 - 越大越好? 比如 >1000T
- 需求2
 - 多台机器存储这些文件
 - 支持多少台机器?
 - 越多越好?

Service 服务

Service 服务

Client

+

Server





多台机器怎么沟通？

社会主义 or 资本主义

Peer to peer
谁也看不惯谁

社会主义





Master + Slave
我们听老大的

资本主义
好比“大哥和他的小弟”

What is master?
Master 也是一台机器

- Peer 2 Peer (BitComet, Cassandra, 不是课程重点, 考察比较少)
 - Advantage
 - 一台机器挂了还可以工作
 - Disadvantage
 - 多台机器需要经常通信保持他们数据一致
- Master Slave
 - Advantage
 - Simple Design
 - 数据很容易保持一致
 - Disadvantage
 - 单master要挂
- Final Decision
 - Master + Slave
 - 单master挂了重启就是。

Storage 存储

数据如何存储

- 大文件存在哪?
 - 内存? 硬盘?

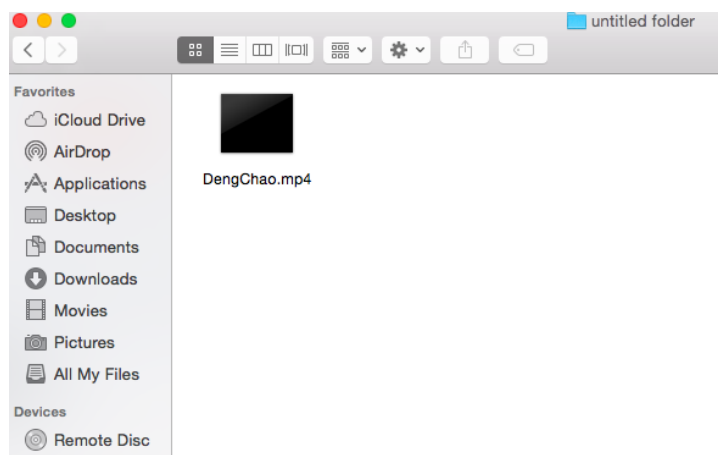
- 大文件存在哪?
 - 内存? 硬盘?
- 怎么存在文件系统里面呢?
 - 怎么设计GFS?

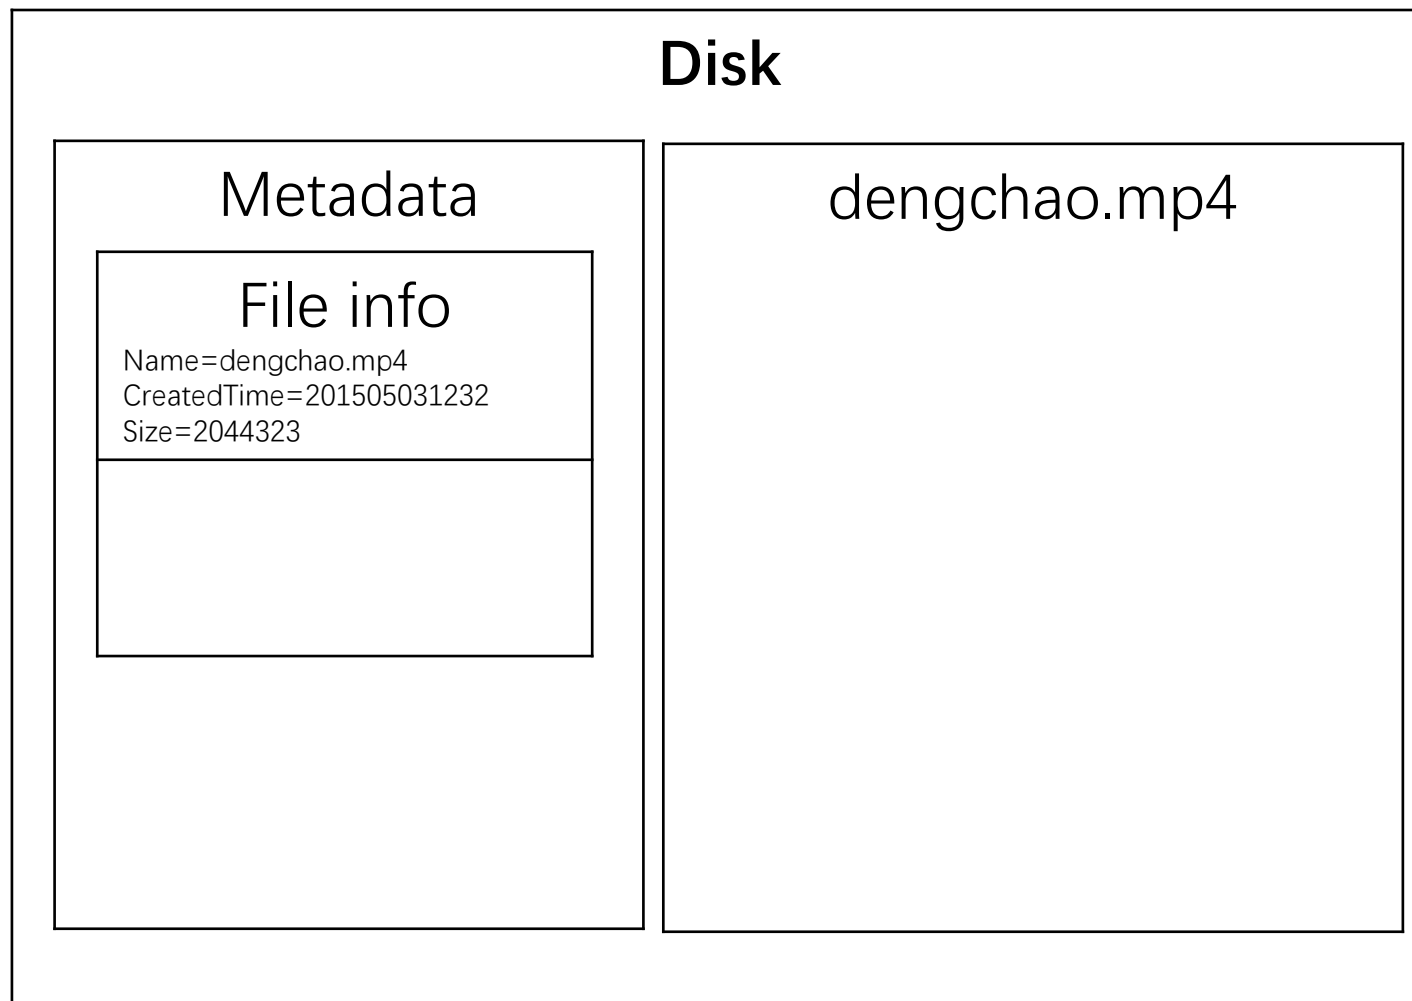
Interviewer: How to save a file
in one machine?

普通的操作系统是怎么做的呢? 100G

DengChao.mp4

一个文件有什么东西?





Metadata: 描述“其他数据”而存储的信息

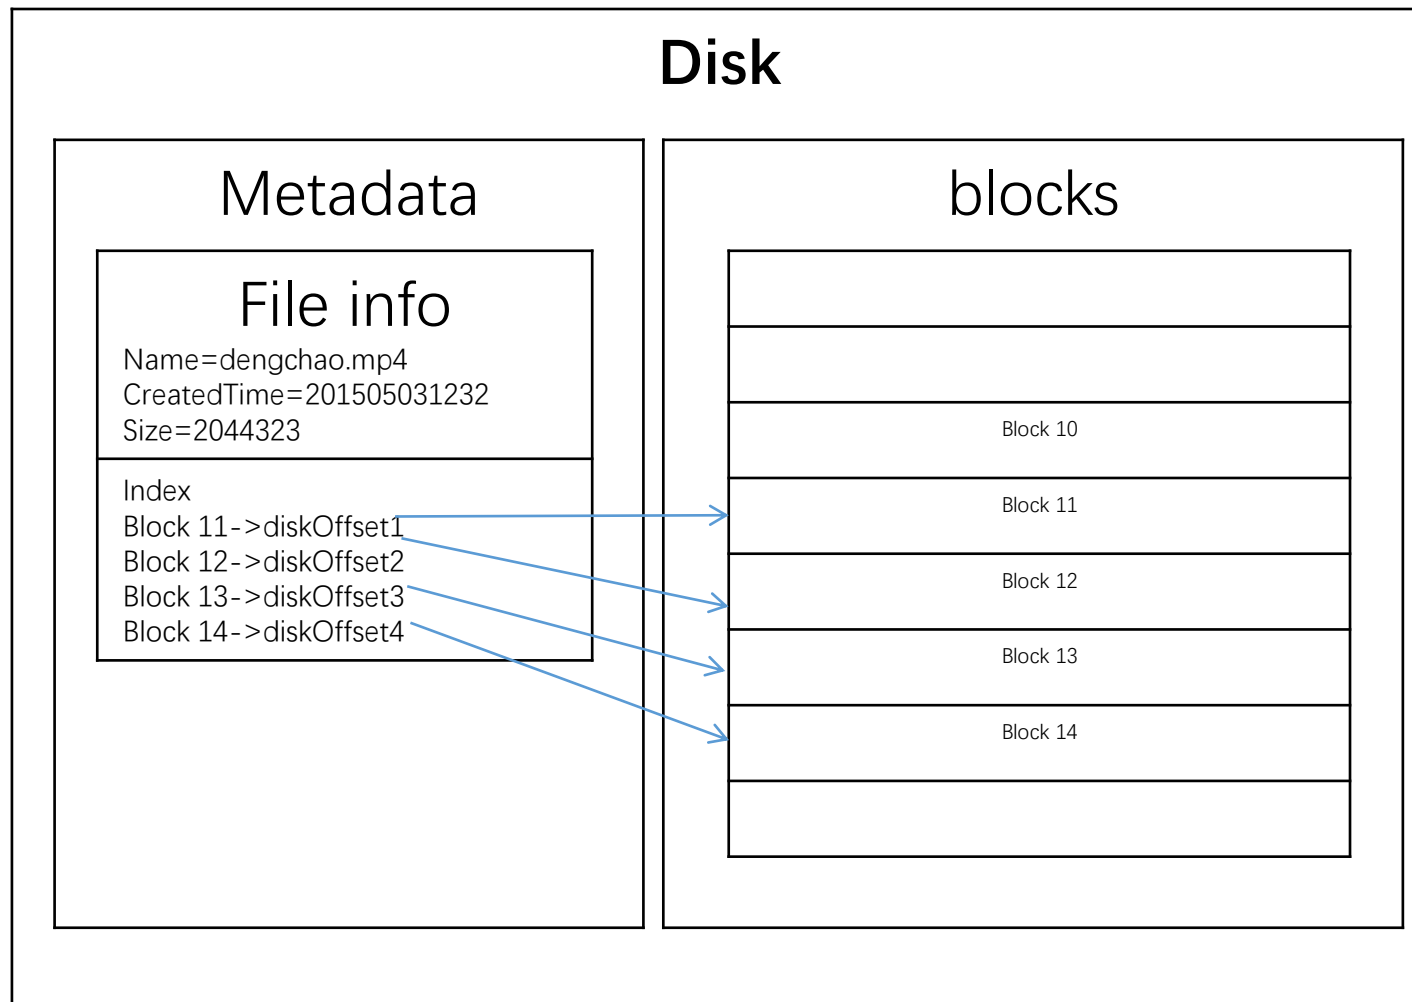
Metadata 访问 常常多于 内容的访问

Metadata 和文件内容是存在一起还是分开?

文件内容是分开存储的呢? 还是连续存储的呢?



How to save a file in one machine



Key point

- 1 block = 4096Byte

Interviewer: How to save a large file
in one machine?

Is block size big enough?

100T(多文件)

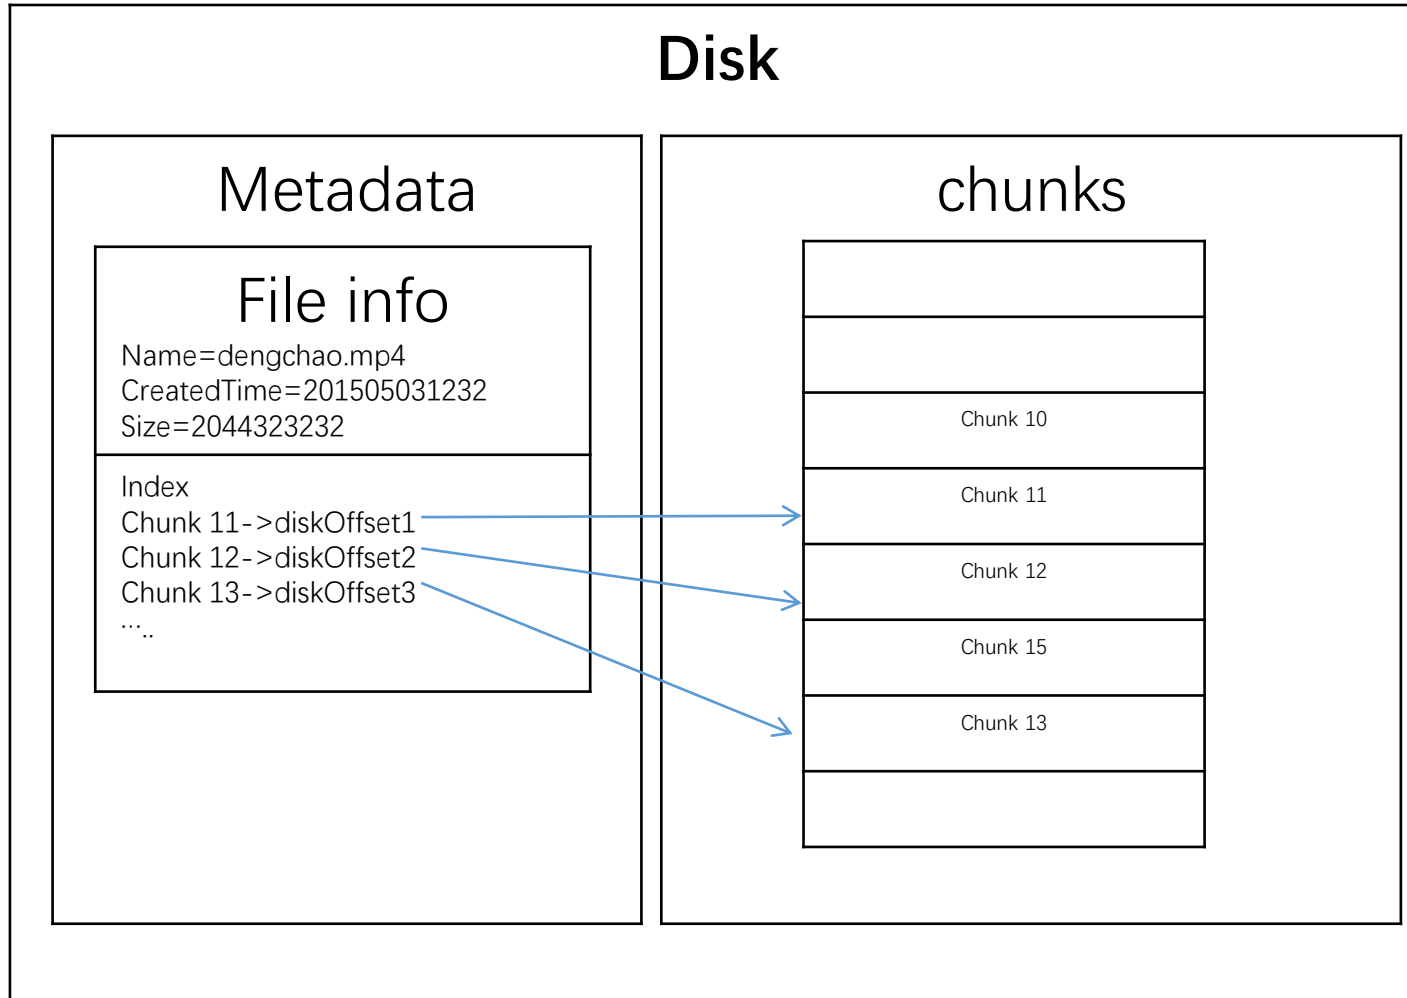
=100*1024G

=100*1024*1024M

=100*1024*1024*1024K

=25*1024*1024*1024block

Interviewer: How to save a large file in one machine?



Key point

- 1 Chunk= 64M
= 64*1024K

Advantage

- Reduce size of metadata

Disadvantage

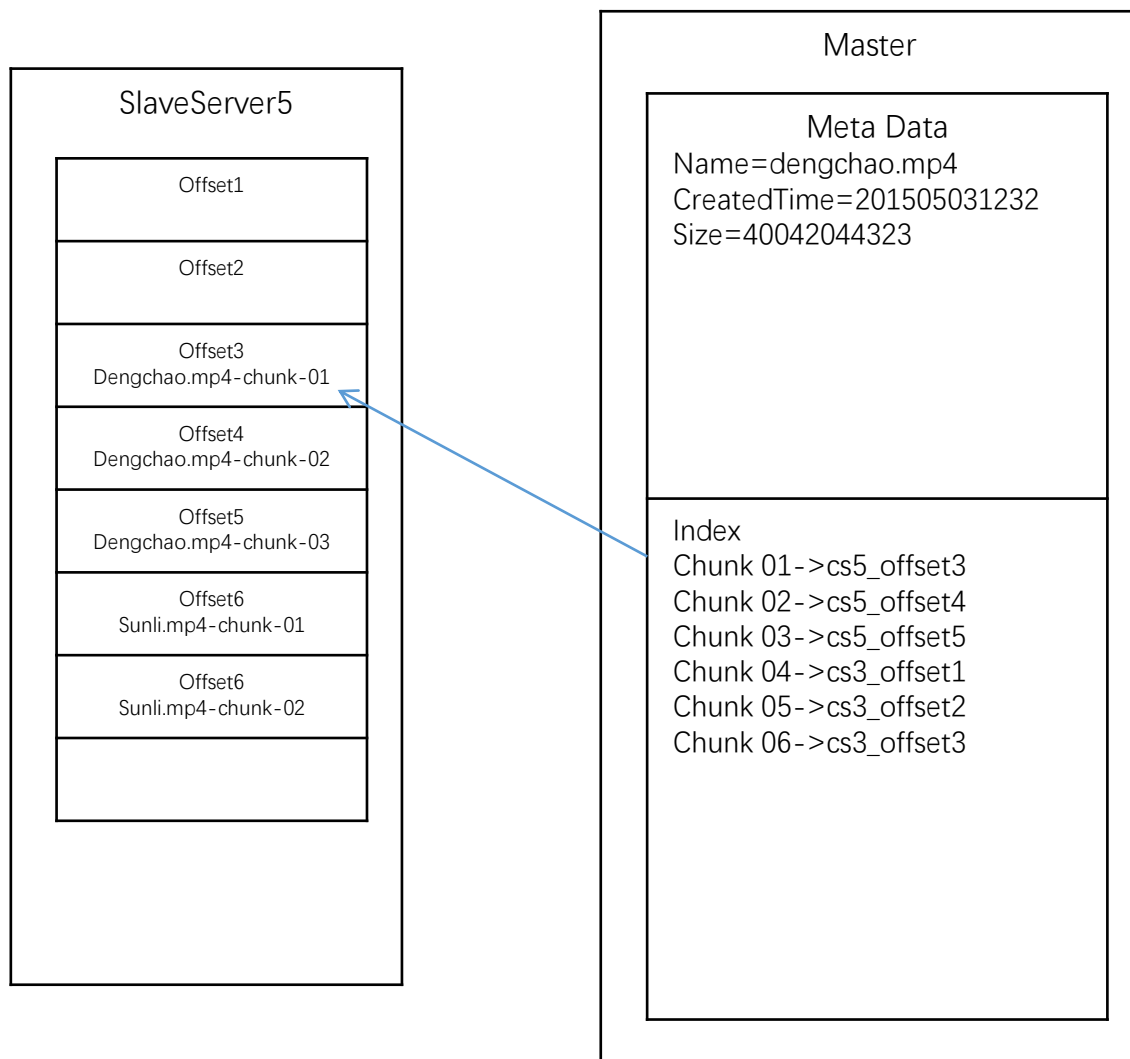
- Waste space for small files

Interviewer: How to save extra-large file
in several machine?

10P

Is one machine big enough?

这里的文件并不是指一个dengchao.mp4就那么大
而是很多个文件

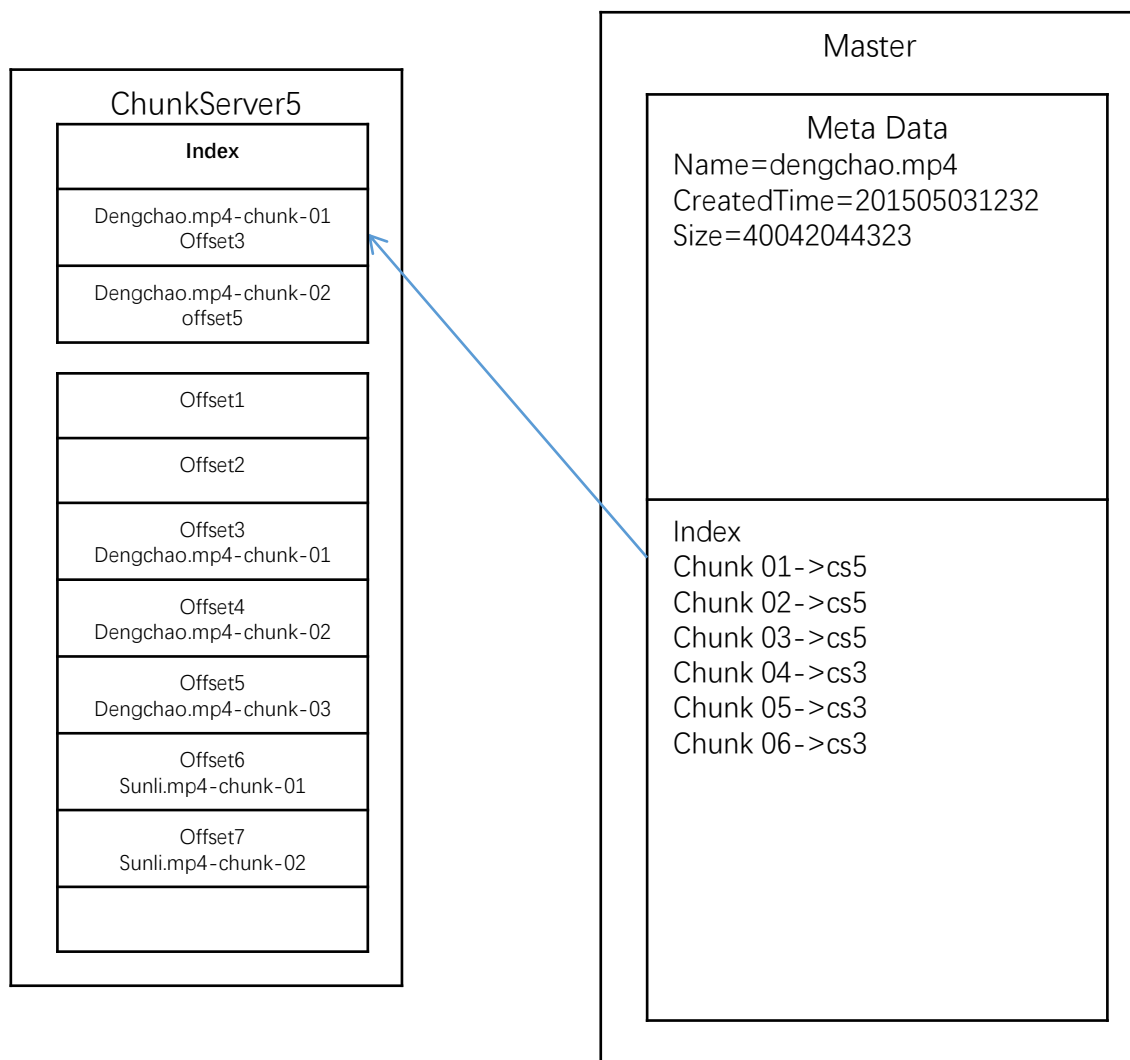


Key point

- One master + many Chunk Servers

Slave Servers = Chunk Servers

每个chunk的Offset偏移量可不可以不存
在master上面？



Key point

- The master don't record the disk Offset of a chunk

Advantage

- Reduce the size of metadata in master
- Reduce the traffic between master and Chunk Server (chunk offset改变不需要通知master)

Master 存储10P 文件的metadata
需要多少容量?

1 chunk = 64MB needs 64B. (经验值)

10P needs 10G

- 按照4S分析
 - **S**enario 场景分析
 - **S**ervice 服务
 - **S**torage 存储
- 理清楚work solution
- Scale 升级优化

One Work Solution for Read / Write




Interviewer: How to write a file?

一次写入 还是拆分成多份多次写入?



write File_name=/gfs/home/dengchao.mp4 →

把大胖子直接写入呢?
还是把大胖子碎尸万段了后写入呢?



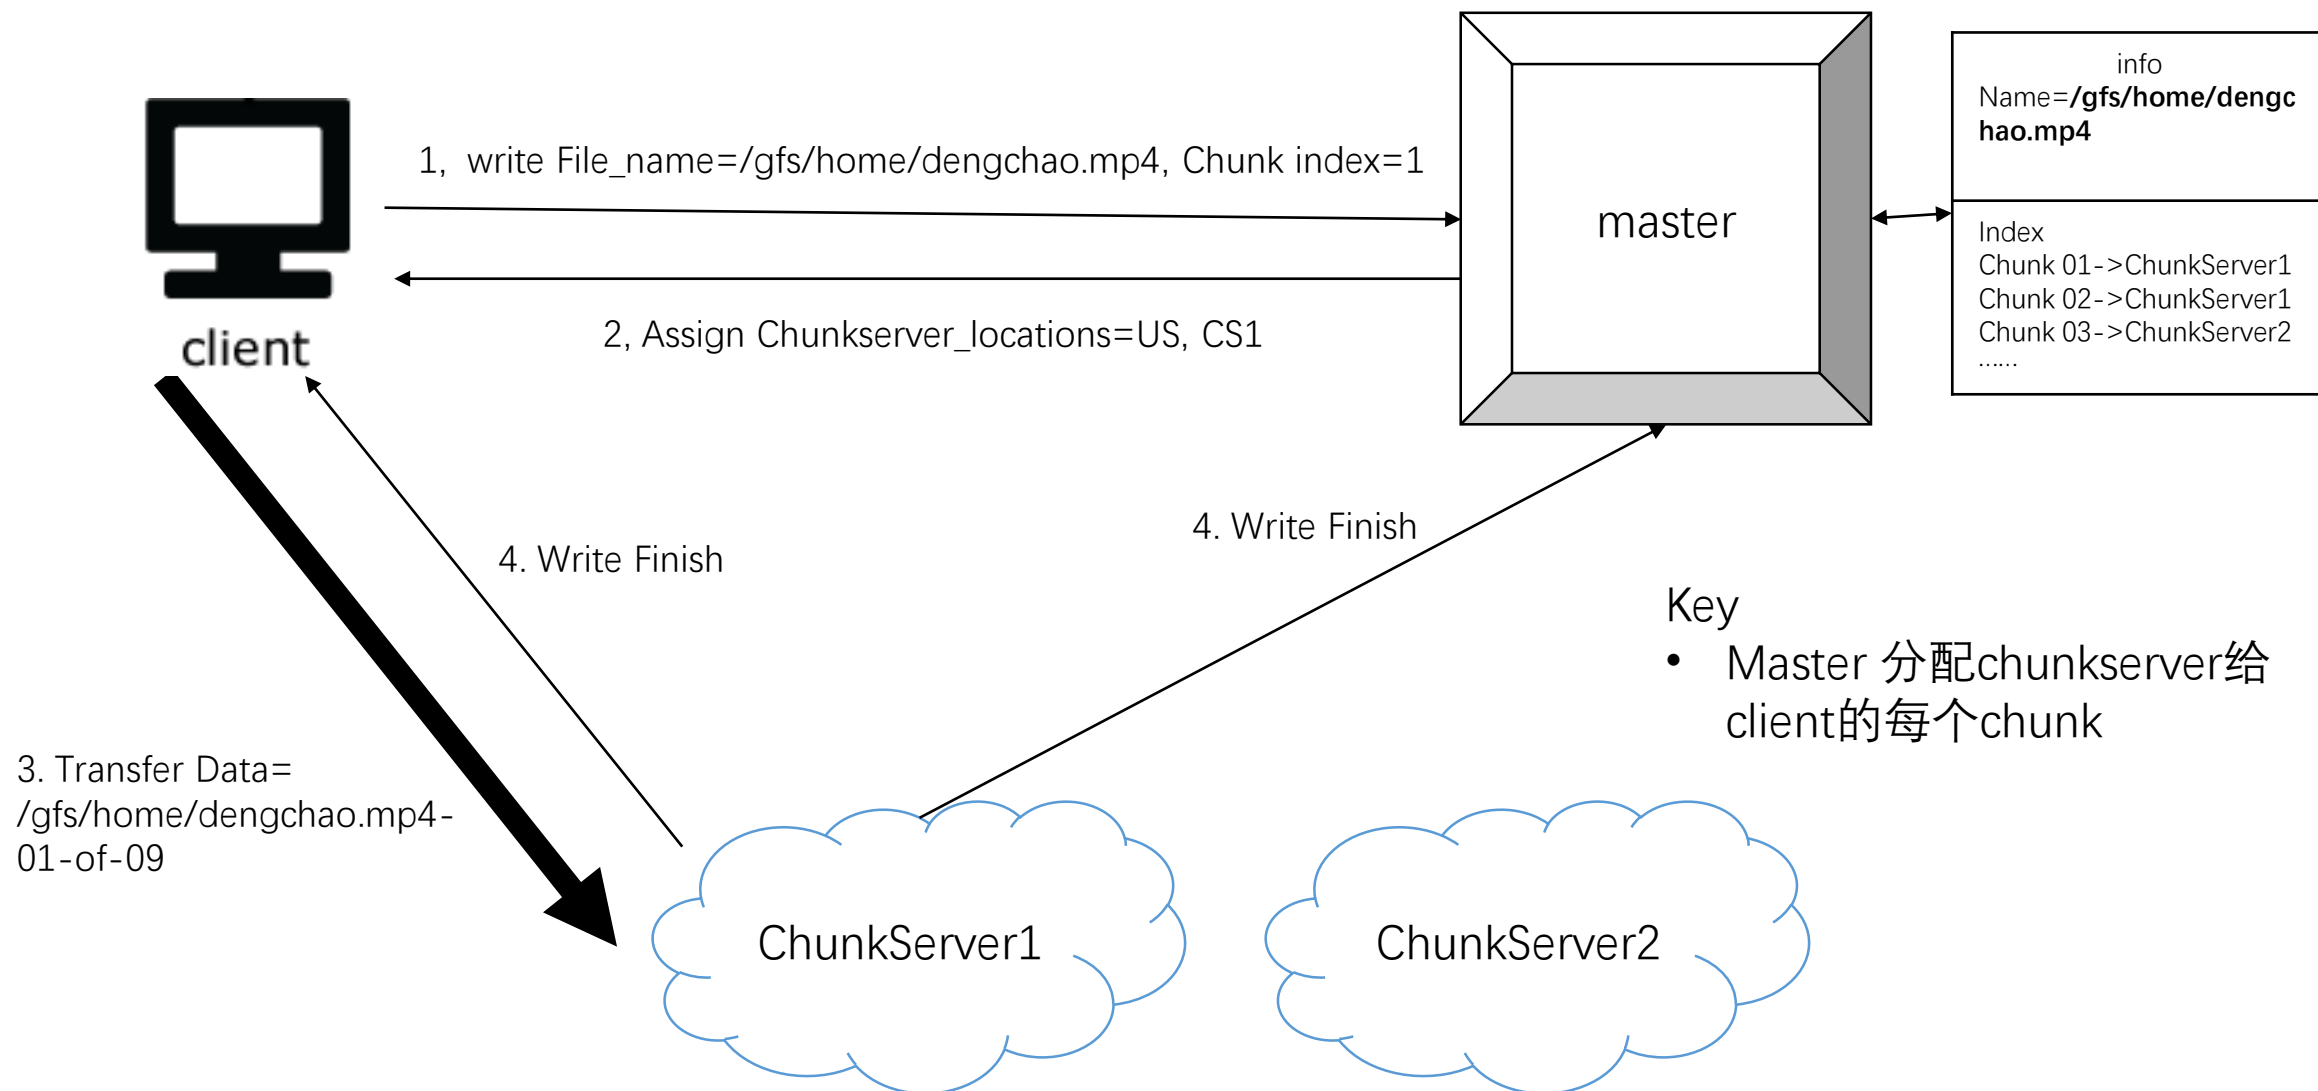
- 写入过程中出错了，那么需要重新写入，哪一种方法更好？
 - 一次传输得重新传输整个文件，多次只用重新传一小份。
- 如果是分成多份多次写入，那么每一份的大小？
 - 文件本来是按照Chunk来存储的，所以传输单位也是Chunk

那每一个chunk是怎么写入server的呢？

直接写到chunk server？

需要先和master沟通，再写入chunk server？

How to write a file?



要修改Dengchao.mp4怎么办?

/gfs/home/dengchao.mp4

要修改的部分在哪个chunk?

修改了过后chunk变大了要怎么处理?

修改了过后chunk变小了要怎么处理?

要修改Dengchao.mp4怎么办?

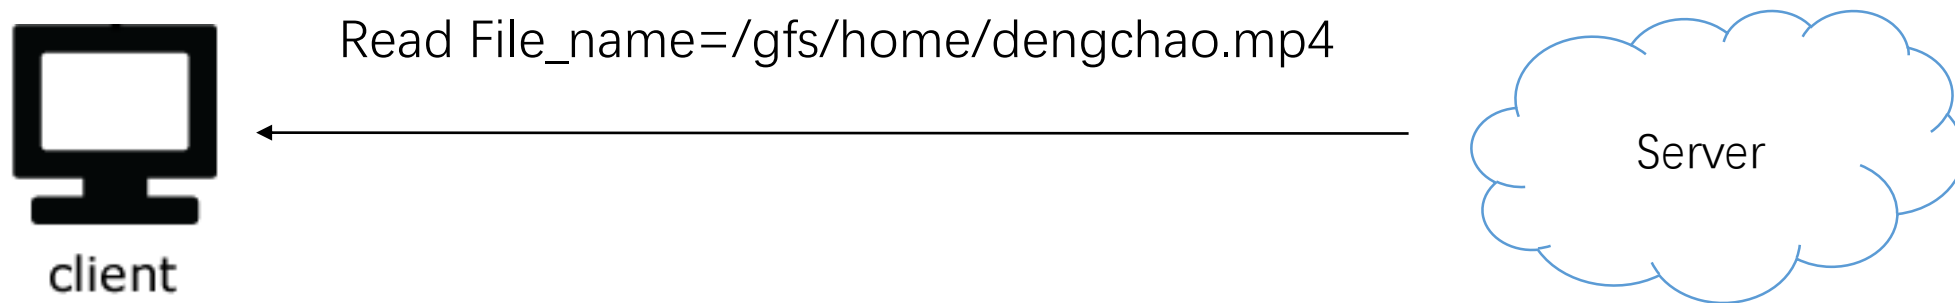
One time to write, Many time to read.

先删掉/gfs/home/dengchao.mp4

重新把整个文件重写一份

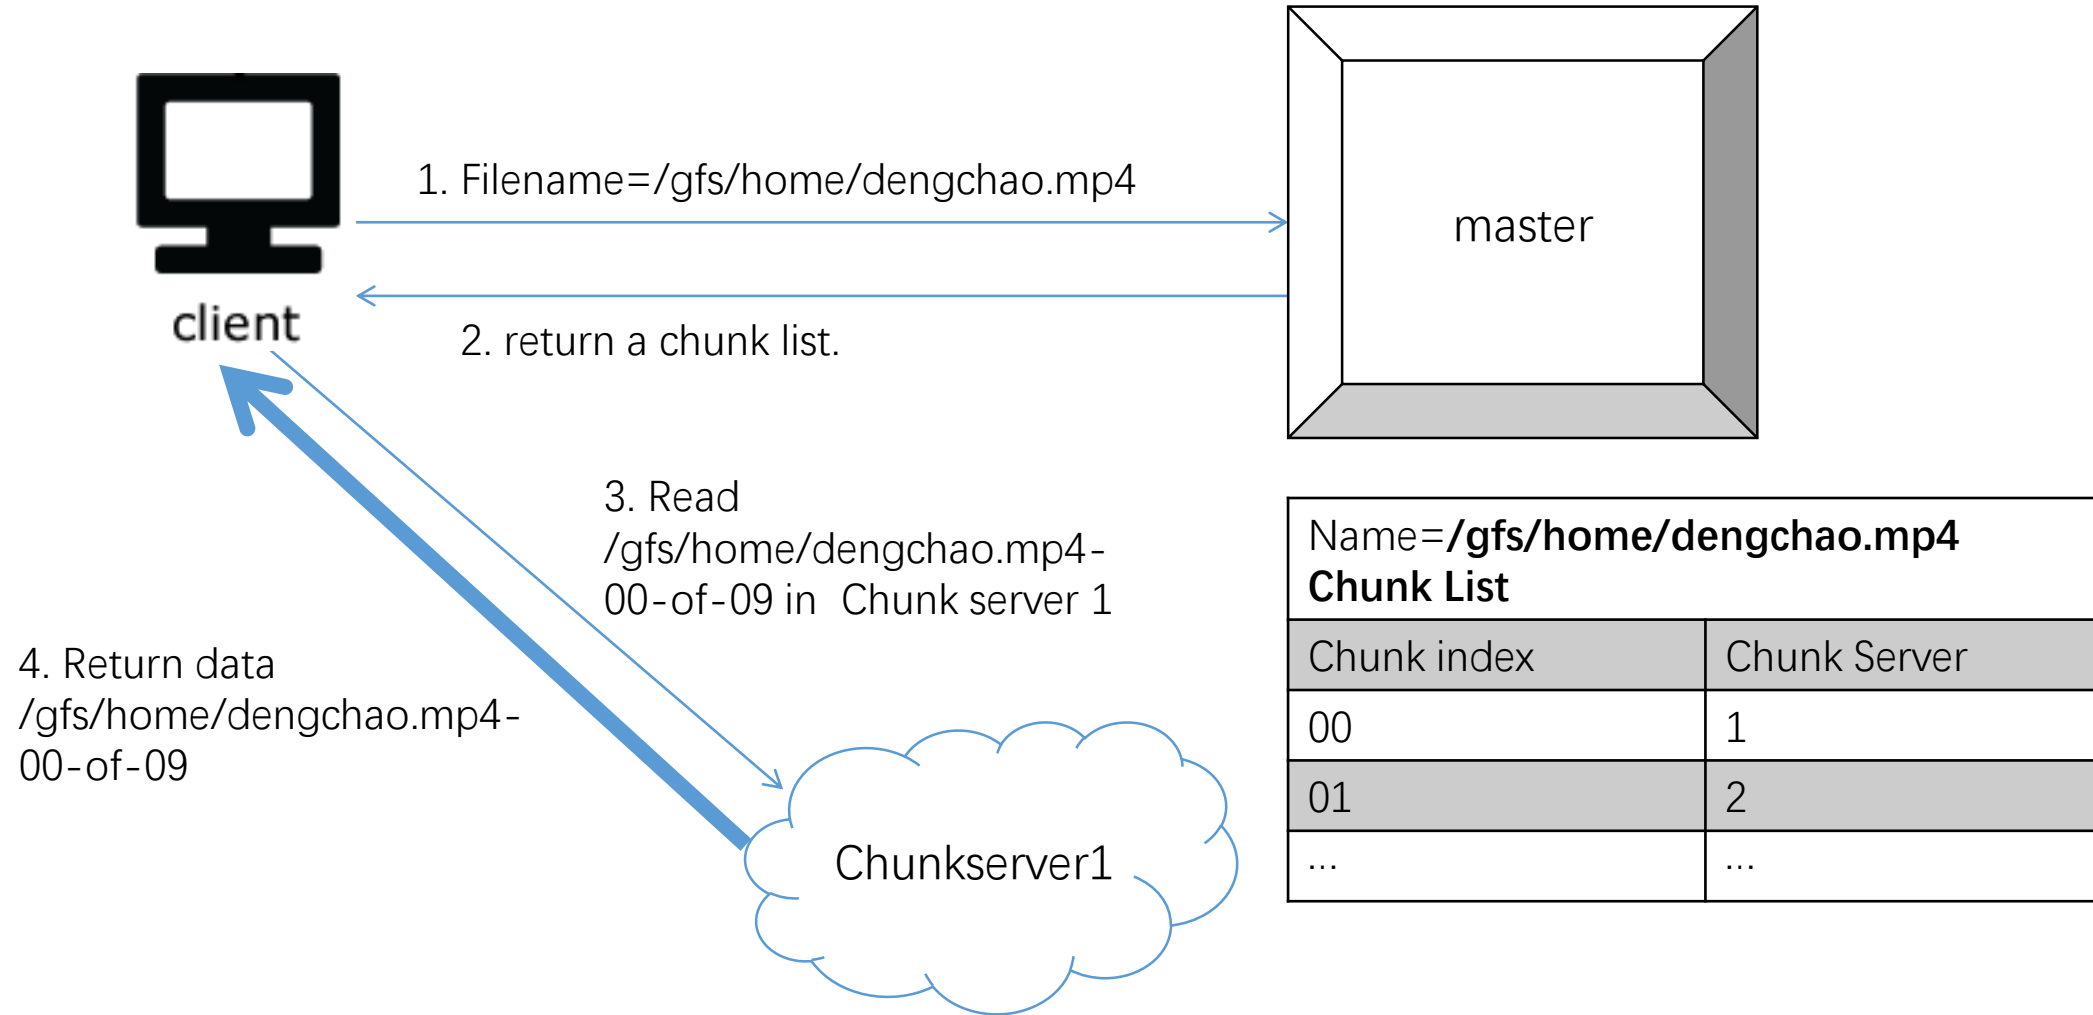
Interviewer: How to read a file?

一次读整个文件？
还是拆分成多份多次读入？



那么client怎么知道dengchao.mp4
被切成了多少块?

How to read from a file?



- 存储各个文件数据的metadata
- 存储Map
 - 读取时找到对应的Chunk Server
 - 写入时分配空闲的Chunk Server

- 存储
 - 普通文件系统 Meta Data, Block
 - 大文件存储: Block-> Chunk
 - 多台机器超大文件: Chunk Server + Master
- 写入
 - Master + Client + Chunk Server 沟通流程
 - Master 维护 metadata 和 Chunk Server 表
- 读出
 - Master + Client + Chunk Server 沟通流程

Scale 升级

系统如何优化与维护

GFS的精髓

单Master 够不够？

单Master 够不够？

工业界90%的系统都采用单master

Simple is perfect

Single Master Failure

Double Master

Paper: [Apache Hadoop Goes Realtime at Facebook](#)

Multi Master

Paper: [Paxos Algorithm](#)

Scale about the Failure and Recover



Interviewer: How to identify whether a chunk on the disk is broken?

Checksum

原来

数据	1	2	3	Checksum(xor)
二进制表示	01	10	11	00

错误后

数据	1	3	3	Checksum(xor)
二进制表示	01	11	11	01

- Checksum Method (MD5, SHA1, SHA256 and SHA512)
- Read More: <https://en.wikipedia.org/wiki/Checksum>

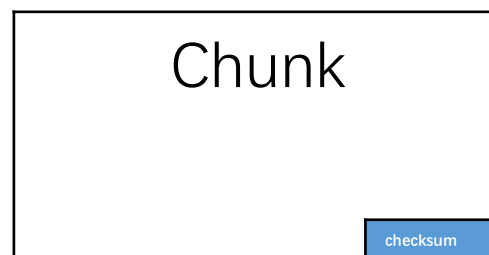
How to identify whether a chunk on the disk is broken?

- 1 Checksum size?
- 4bytes = 32bit
- 1 chunk = 64MB
- Each chunk has a Checksum
- The size of Checksum of 1P file
- $1P/64MB \times 32bit = 62.5 \text{ MB}$

什么时候写入checksum?

什么时候写入checksum?

Answer: 写入一块chunk的时候顺便写入



什么时候检查checksum?

什么时候检查checksum?

Answer: 读入这一块数据的时候检查

1. 重新读数据并且计算现在的checksum
2. 比较现在的checksum和之前存的checksum是否一样

Interviewer: How to avoid chunk data loss when a Chunk Server is down/fail?

Interviewer: How to avoid data loss
when a Chunk Server is down/fail?

Answer: Replica (专业词汇)
做备份

需要多少个备份?
每个备份放在哪?

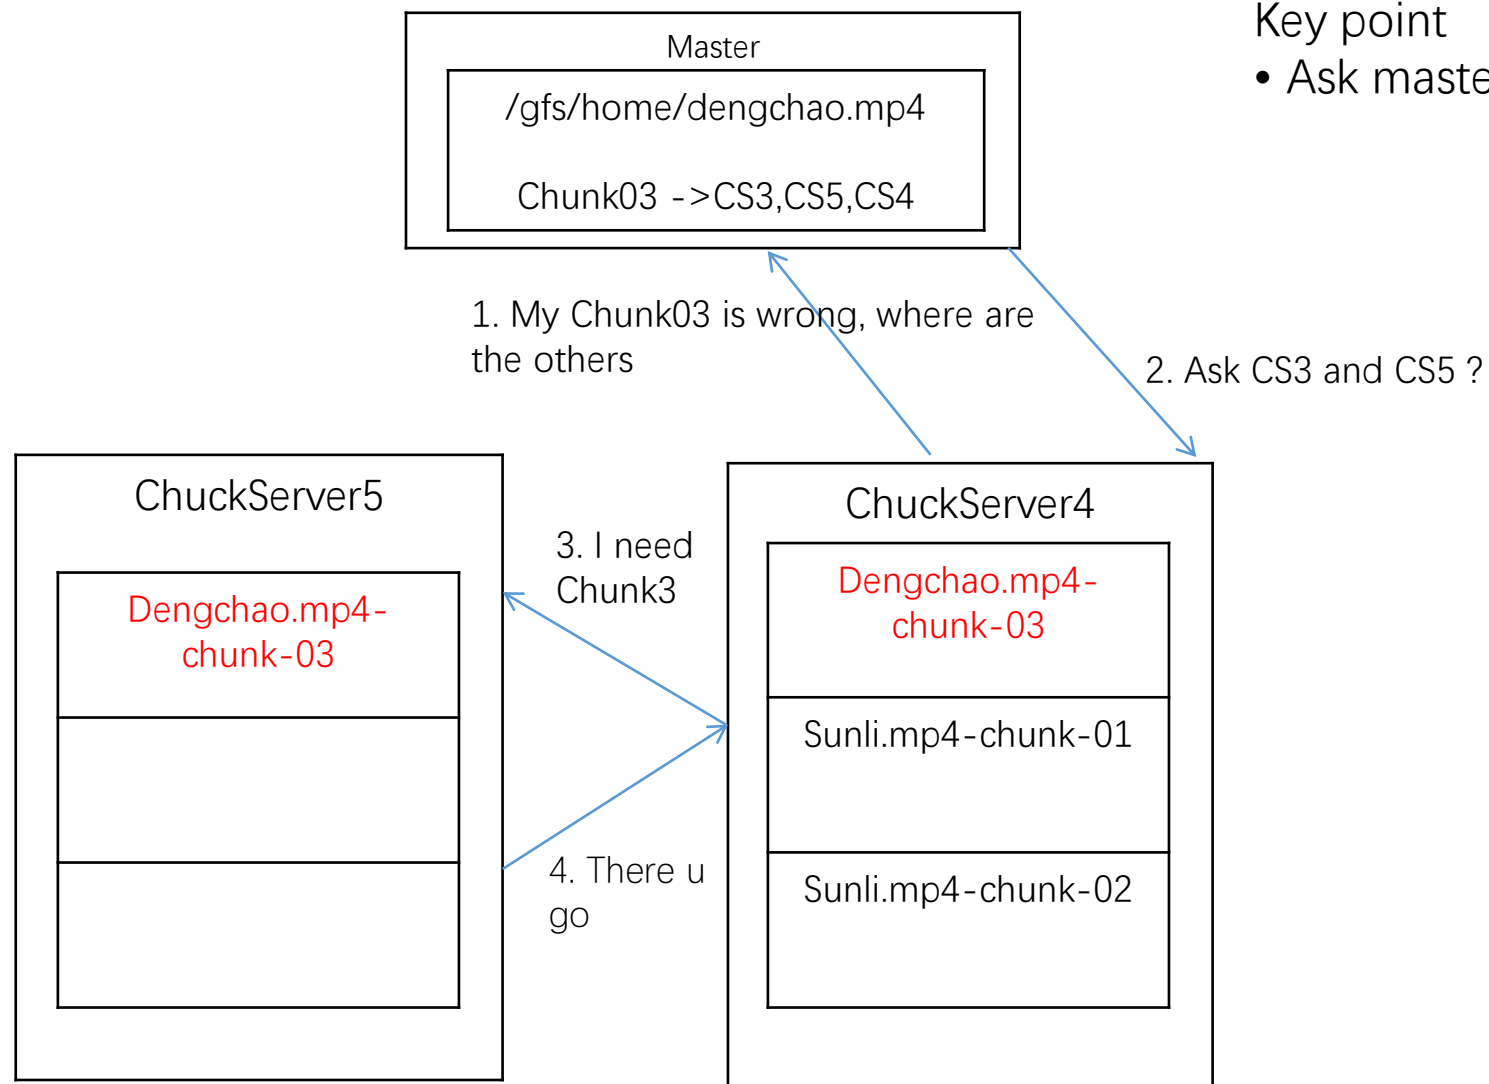
需要多少个备份?
每个备份放在哪?

1. 三个备份都放在一个地方(加州)。
2. 三个备份放在三个相隔较远的地方 (加州, 滨州, 纽约州)
3. 两个备份相对比较近, 另一个放在较远的地方 (2个加州, 1个滨州)

Interviewer: How to recover when a chunk is broken?

Interviewer: How to recover when a chunk is broken?

Answer: Ask master for help



Key point

- Ask master for help

How to find whether a Chunk
Server is down?

How to find whether a Chunk Server is down?

Answer: Heart Beat.

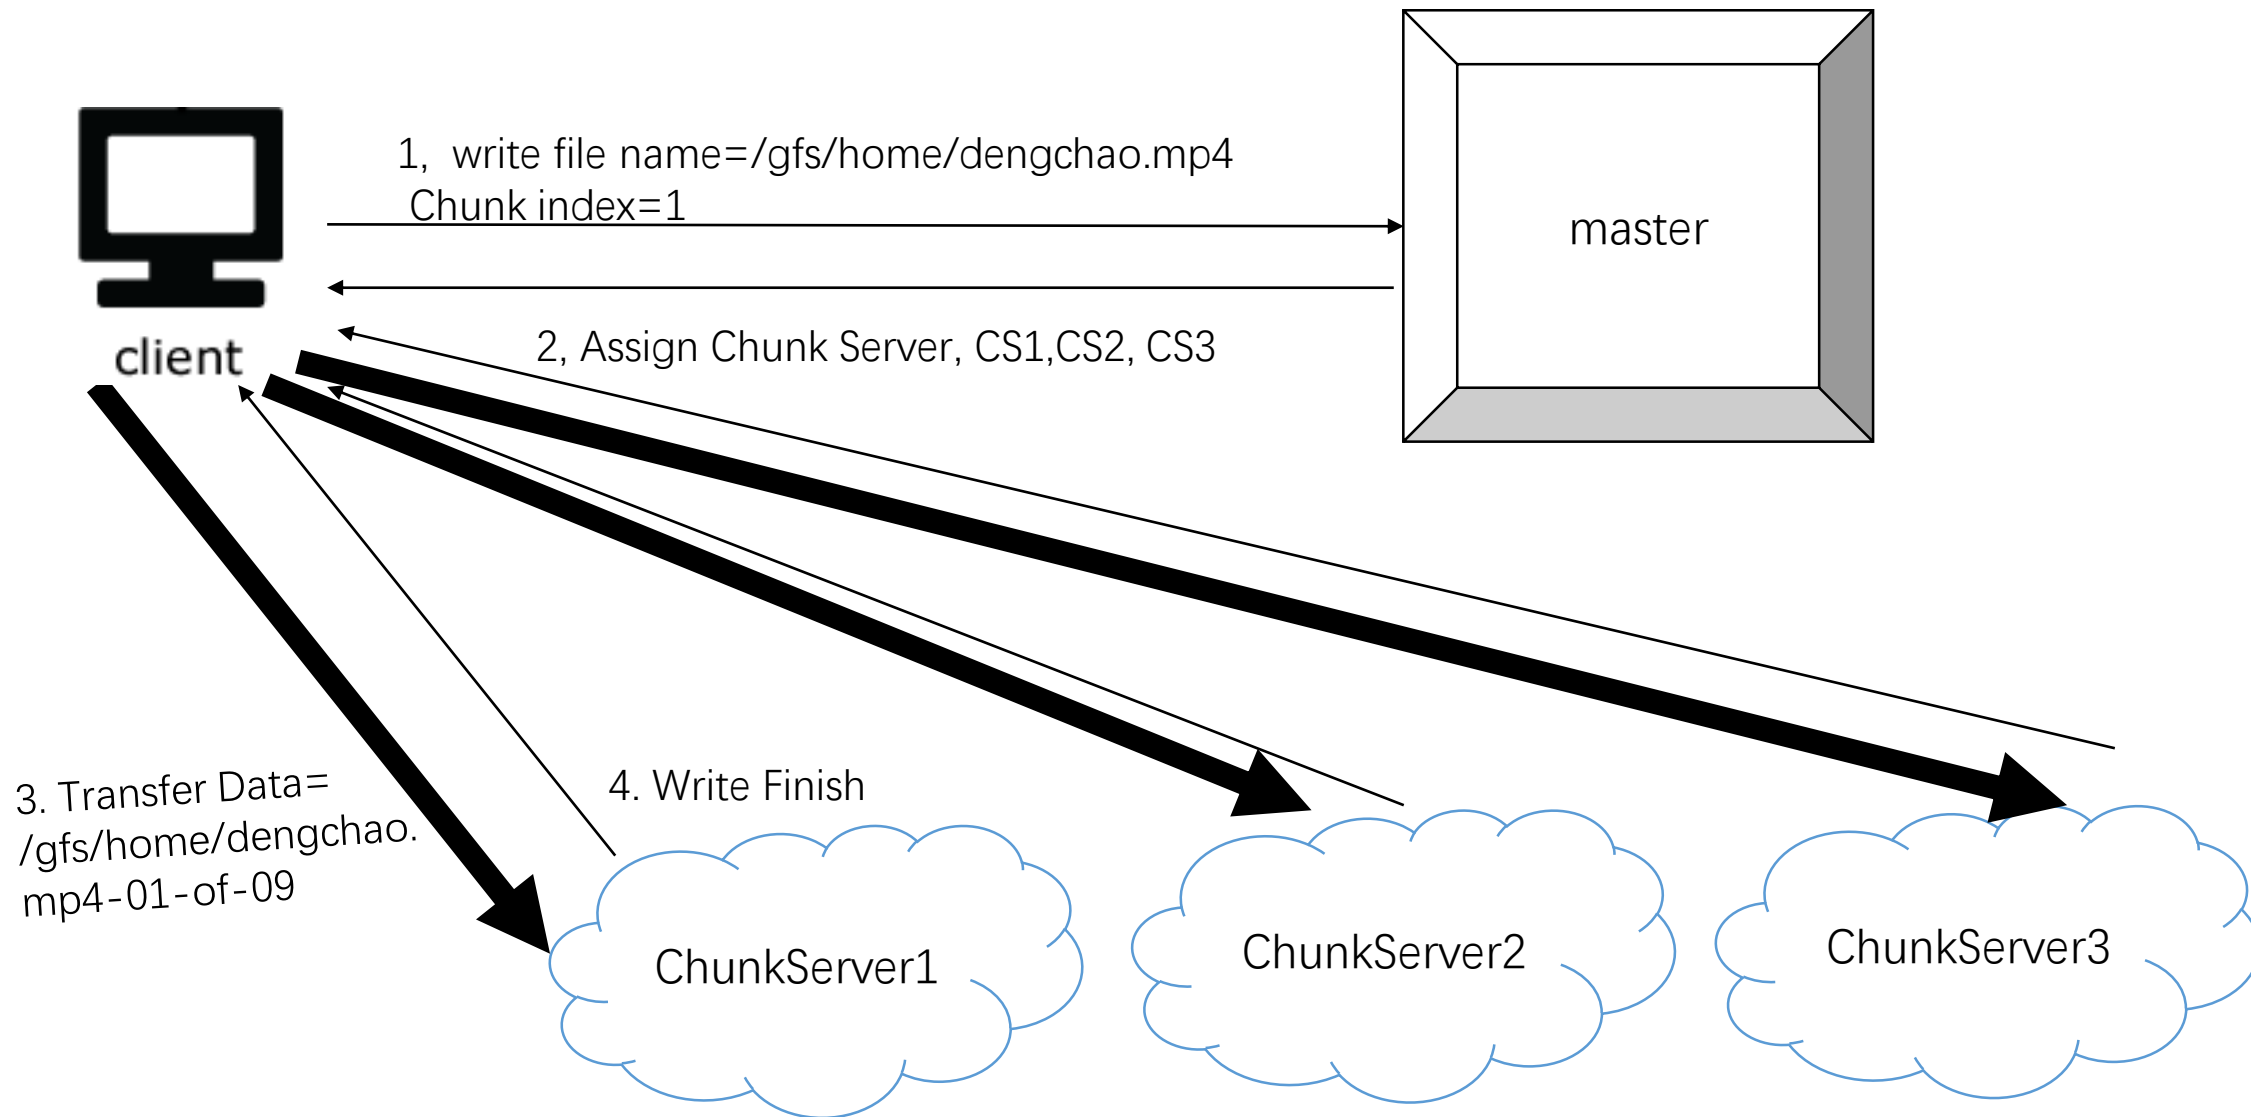
A: master -> chunk servers?

B: chunk servers->master?

Scale about the Write

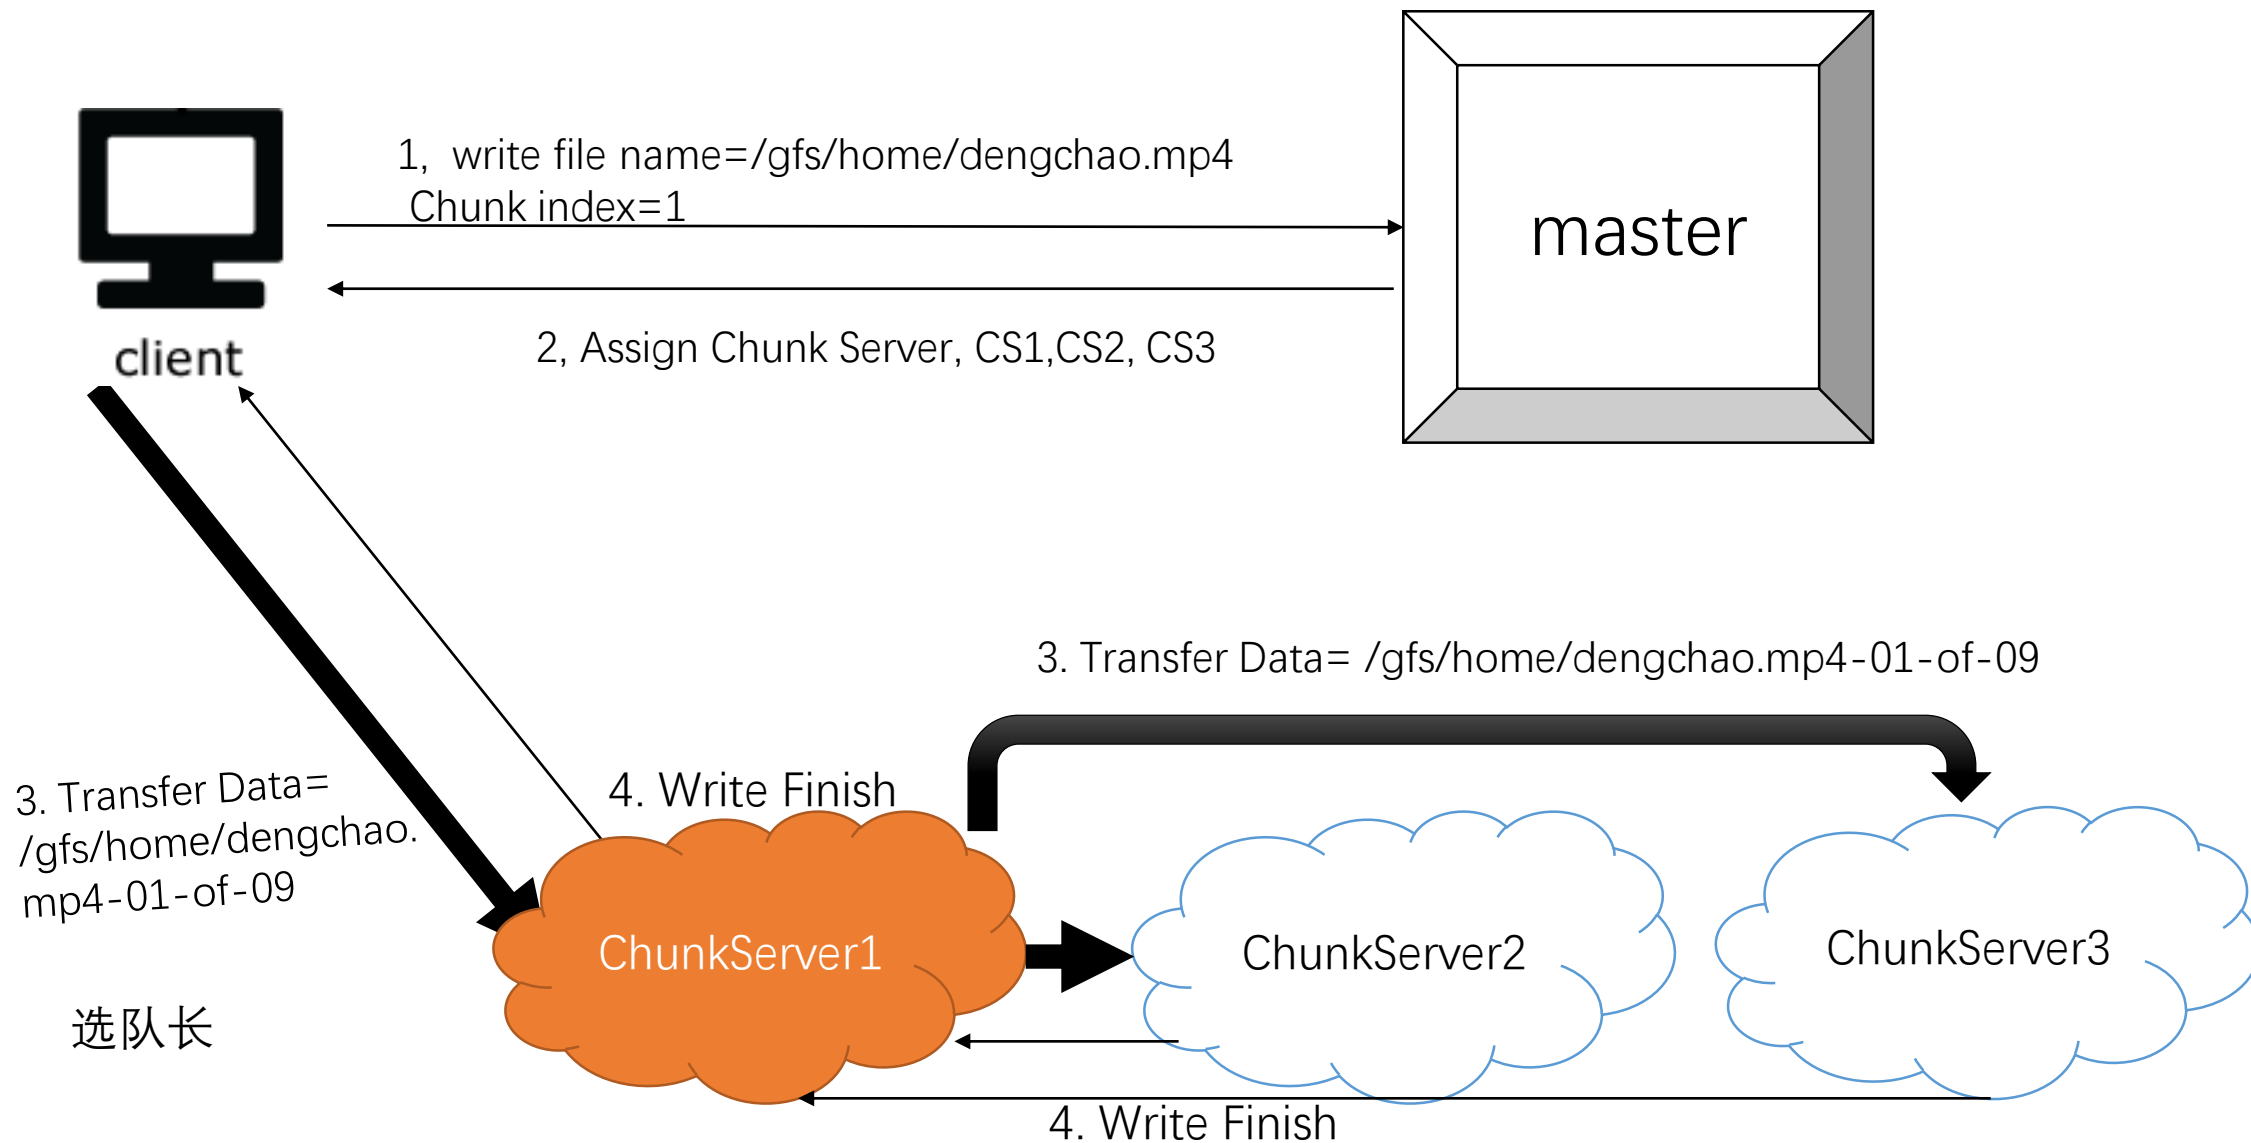
Interviewer: Whether write to only one server is safe?

How to write a file?



Interviewer: How to solve Client
bottleneck?

How to solve Client bottleneck?

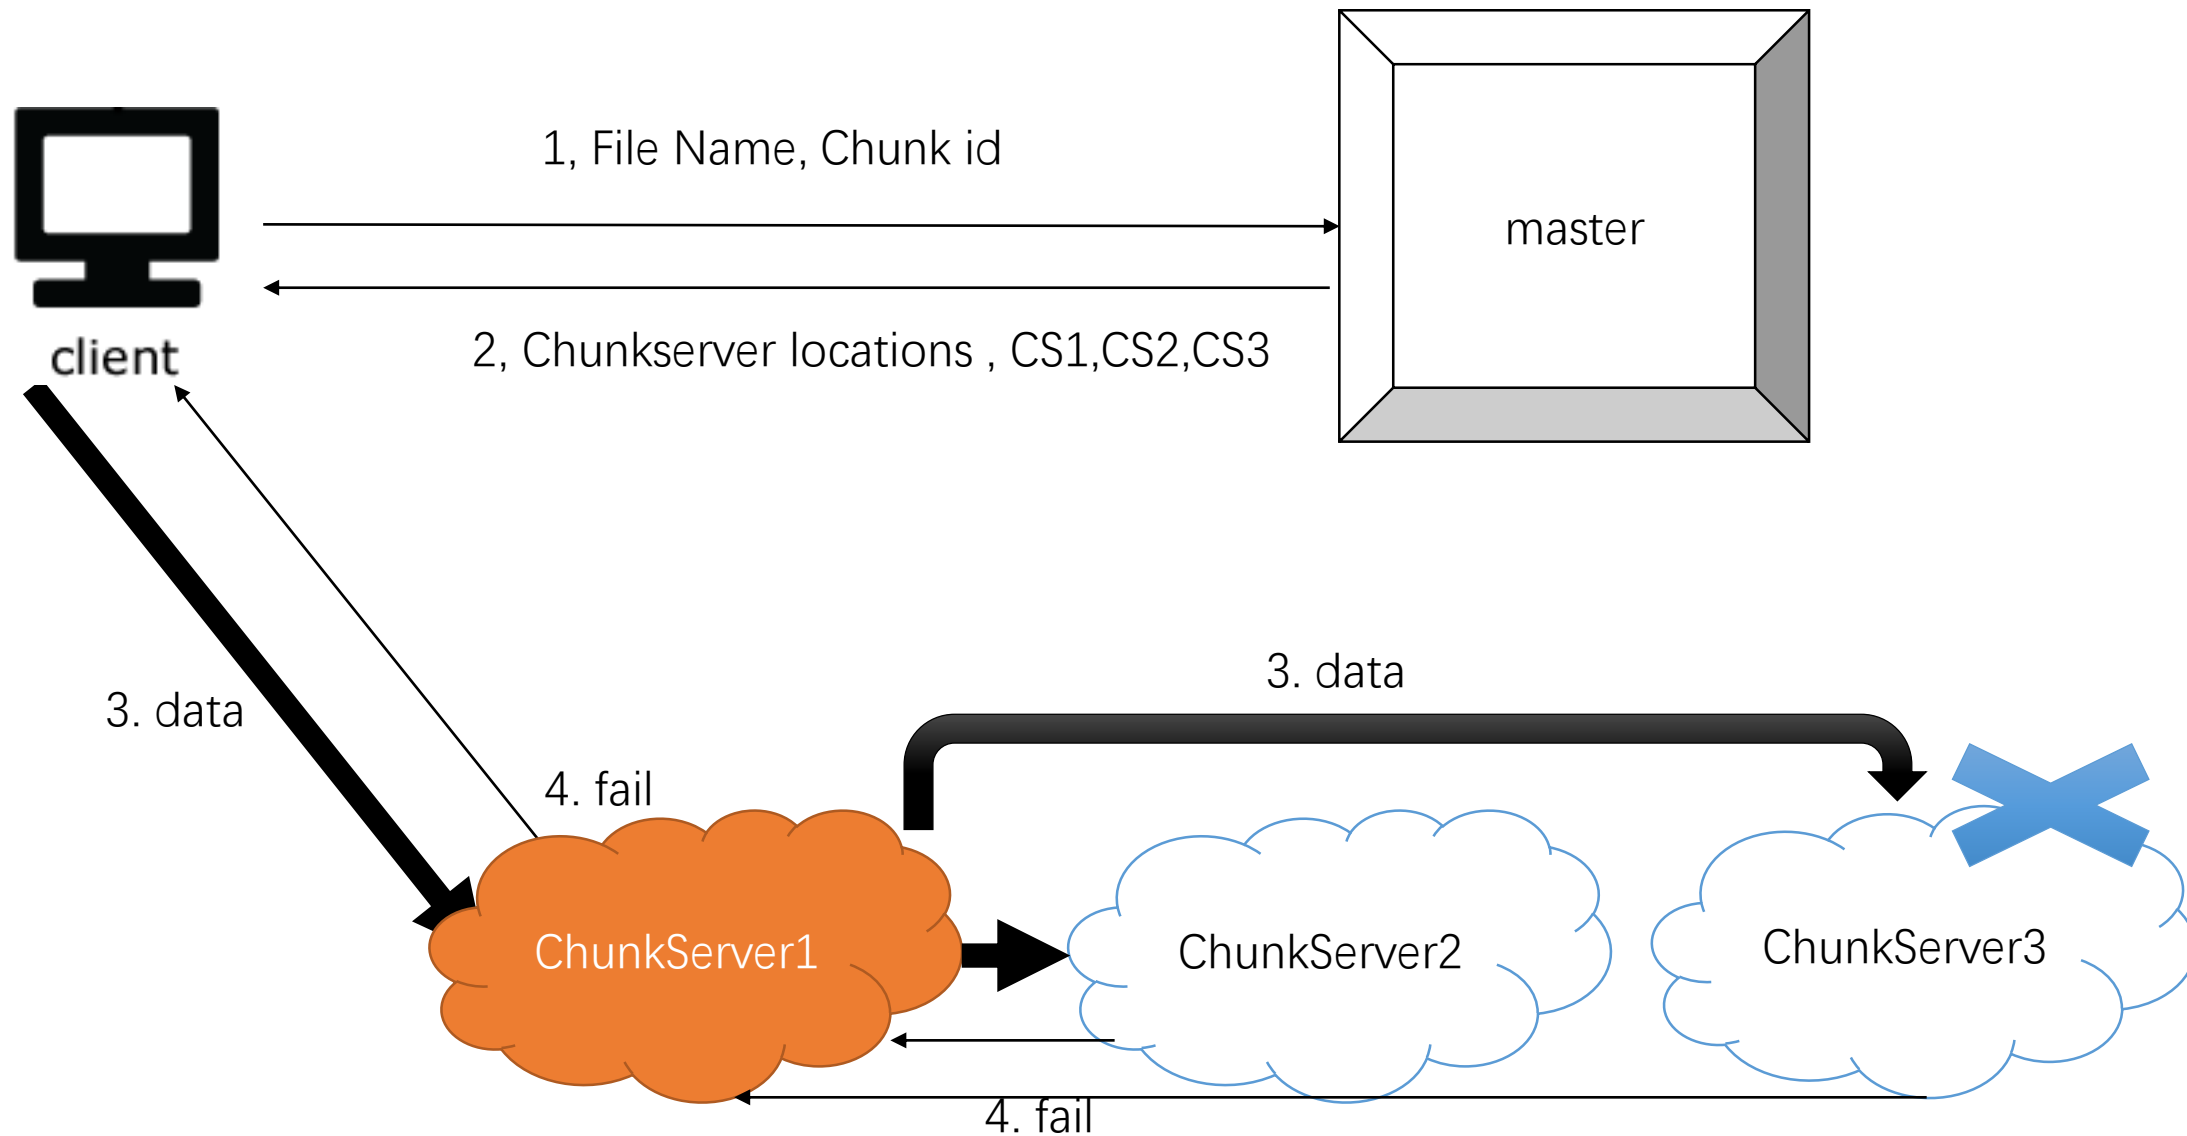


Interviewer: 怎么样选队长?

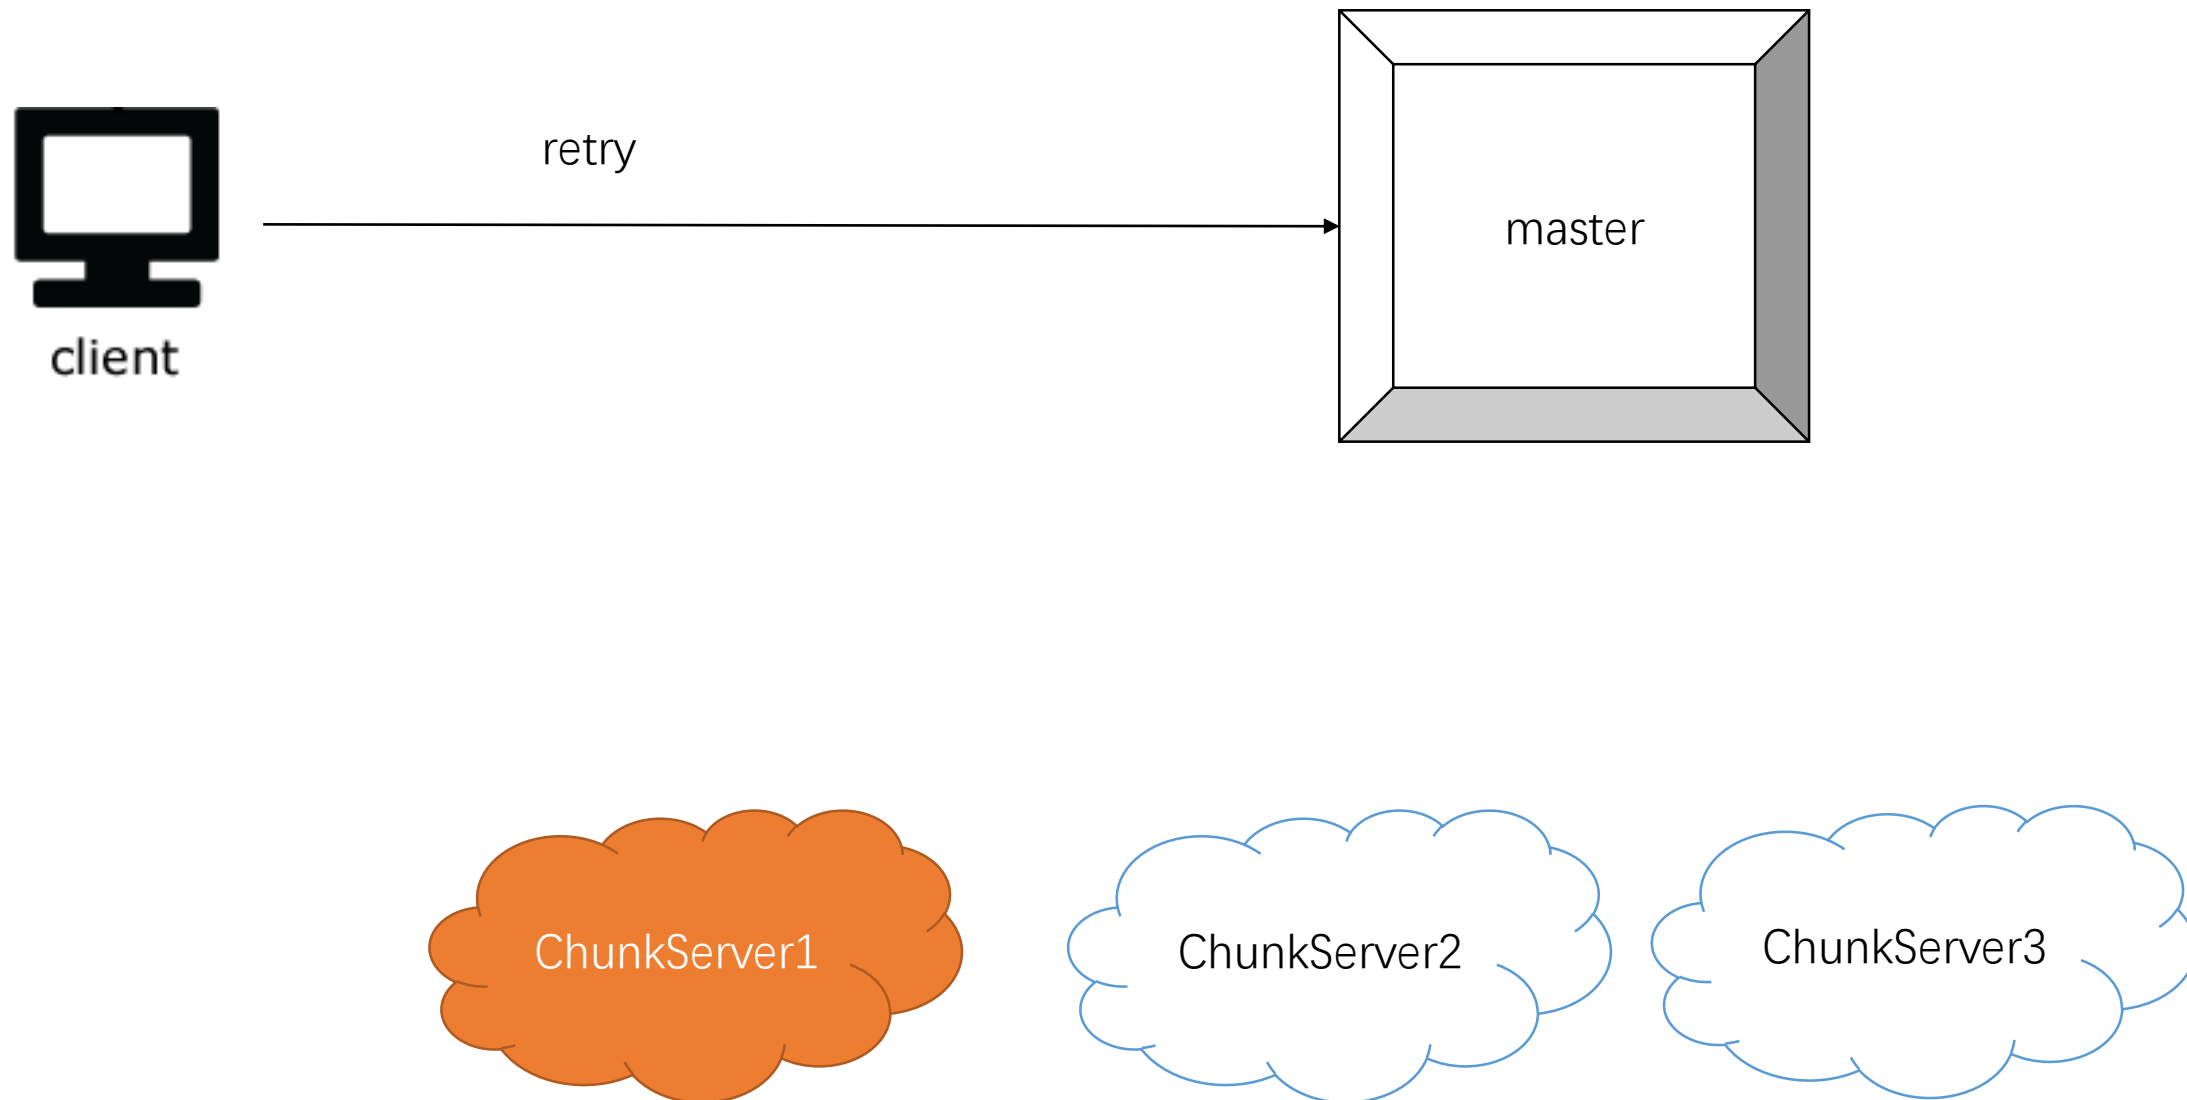
1. 找距离最近的 (快)
2. 找现在不干活的 (平衡traffic)

Interviewer: How to solve Chunk
Server failure?

How to solve Chunk Server failure?



How to solve Chunk Server failure?



- Key Point: Master-Slave
- Storage:
 - Save a file in one machine -> a big file in one machine -> a extra big file in multi-machine
 - Multi-machine
 - How to use the **master**?
 - How to traffic and storage of master?
- Read:
 - The process of reading a file
- Write:
 - The process of writing a file
 - How to reduce master traffic?
 - Client 和 Chunk Server沟通
 - How to reduce client traffic?
 - Leader Election
- Failure and Recover (key)
 - Discover the failure a chunk?
 - **Check Sum**
 - Avoid the failure a chunk?
 - **Replica**
 - Recover the failure?
 - Ask master
 - Discover the failure of the Chunk Server?
 - **Heart Beat**
 - Solve the failure of writing Chunk Server?
 - Retry

Google onsite non-abstract large scale system design 真题

<https://www.jiuzhang.com/qa/627/>

- Expert/Master, <http://url.cn/dOLFCs>
- Expert/Master, <http://url.cn/eErkhm>
- Expert/Master, <http://url.cn/LqTkoa>

- 为什么说学习GFS对我们其他的系统设计也有好处呢？
 - Master Slave Pattern
 - How to handle failure
 - How to use GFS



扫描二维码关注微信/微博
获取最新面试题及权威解答

微信: [ninechapter](#)

知乎专栏: <http://zhuanlan.zhihu.com/jiuzhang>

微博: <http://www.weibo.com/ninechapter>

官网: www.jiuzhang.com